¿A qué perfiles dirigir las ventas de bicicletas?

Machine Learning for Business · Proyecto 1 · Facultad de Ciencias Económicas · 2026
Autores: Juan Diego Letona (20230285) y Jose Tanchez (20230005) · Dataset 2: *Sales Data* (Kaggle) · Metodología CRISP-DM

0.665	**1.7×**	**46.5 %**	**LightGBM**
ROC-AUC en datos no vistos (azar = 0.500)	Lift del 10 % de perfiles mejor puntuado	de las bicicletas capturadas contactando al 30 % mejor puntuado	modelo seleccionado, ajustado con Optuna

1. Introducción (*Introduction*)

La empresa vende bicicletas, accesorios y ropa de ciclismo en seis mercados. Las bicicletas son solo el 17 % de los pedidos, pero generan el 51 % de la ganancia: cada una deja en promedio 5.3 veces la ganancia de un pedido de otra categoría. Saber **a qué perfiles de cliente conviene ofrecerlas**, y a cuáles conviene ofrecer accesorios o ropa, permite usar mejor un presupuesto comercial limitado.

Este informe resume un modelo de *Machine Learning* que, usando únicamente lo que se conoce **antes de la compra** (edad, género, país, estado y mes), estima la probabilidad de que un pedido sea una bicicleta, y lo traduce en recomendaciones por edad, género y mercado. El trabajo sigue las fases de CRISP-DM [1]; el código completo y todas las verificaciones están en el cuaderno adjunto.

2. Problema de negocio (*Business problem*)

Elemento	Descripción
Contexto	Venta de bicicletas, accesorios y ropa en EE. UU., Canadá, Reino Unido, Alemania, Francia y Australia.
Stakeholder	Gerencia de Marketing y Ventas Regionales: decide a qué perfiles, mercados y momentos del año dirigir cada línea de producto.
Pregunta	Conociendo solo edad, género, país, estado y mes, ¿qué probabilidad hay de que un pedido sea una bicicleta y qué perfiles conviene priorizar?
Objetivo analítico	Clasificación binaria («¿es bicicleta?») con salida probabilística, para ordenar perfiles de mayor a menor propensión.
Variables excluidas	Producto, precio, costo, cantidad, ingreso y ganancia: determinan la categoría comprada o son su consecuencia (fuga de información) [2]. Con solo precio y costo unitarios el modelo «acertaría» casi perfectamente, pero sería inútil porque esos datos no existen antes de comprar.
Métricas de éxito	*Técnicas:* PR-AUC (principal), ROC-AUC y *log-loss* en datos no vistos, superiores a una línea base [3]. *Comerciales:* porcentaje de bicicletas y de ganancia capturado al contactar solo al *k* % mejor puntuado, frente al azar [4].
Impacto esperado	Concentrar el esfuerzo en los perfiles de mayor propensión y reorientar los de menor propensión a accesorios y ropa, mejorando la eficiencia del contacto sin ampliar el presupuesto.

3. Datos (*Data*)

Fuente. *Sales Data* (Kaggle) [5]: 113,036 líneas de pedido y 18 columnas (fecha, edad y género del cliente, país, estado, producto, cantidades y montos), de 2011 a 2016. No existe identificador de cliente: cada fila es una línea de pedido.

Hallazgo	Evidencia	Decisión
Faltantes	Ninguno en las 18 columnas.	No se imputa.
Duplicados	1,000 filas idénticas (0.9 %).	Se eliminan (quedan 112,036).
Consistencia	Costo, ganancia y fechas cuadran en el 100 % de las filas.	Sin correcciones.
Etiquetas de catálogo	4 productos con más de una categoría (10 filas) y 8 con más de una subcategoría.	Se usa la etiqueta mayoritaria de cada producto.
Atípicos	Edades hasta 87 años y ganancias altas (bicicletas caras): son ventas reales.	Se conservan; los árboles son robustos a ellos.
Cambio de catálogo	Antes de julio de 2013 solo se vendían bicicletas; julio de 2013 es el lanzamiento de las demás líneas y en julio de 2014 y 2016 no hay bicicletas. Esos meses tienen 62.6 % de bicicletas frente a 16.6 % en el resto.	Se conservan solo los 22 meses con las tres categorías (96,359 pedidos); son otro régimen de catálogo, no comportamiento del cliente (gráfico en el cuaderno, sección 3.2).
Registros «gemelos»	Los pedidos del mismo día, edad, género y estado forman 19,320 grupos, y todos reaparecen en un segundo año con cantidades distintas.	Toda partición se hace **por grupos** para que el modelo no memorice registros repetidos.

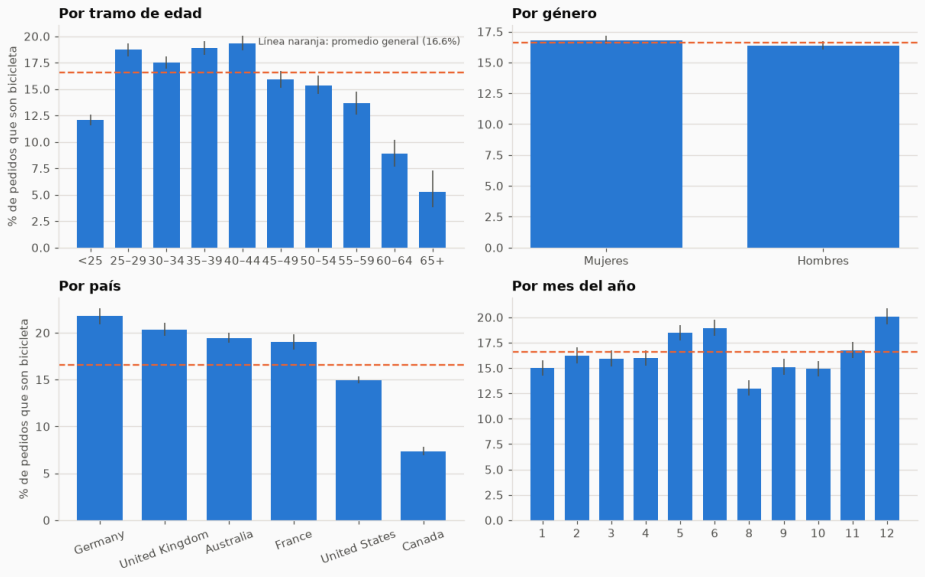


Figura 1. Porcentaje de pedidos que son bicicleta según edad, género, país y mes (barras con intervalo de confianza del 95 %; línea naranja: promedio general, 16.6 %).

4. Métodos (*Methods*)

4.1 Diseño experimental

El 20 % de los grupos (19,108 pedidos) se reserva como **conjunto de prueba**, que no interviene en ninguna decisión de modelado y se evalúa una sola vez. Con el 80 % restante (77,251 pedidos) se hace validación cruzada de 5 pliegues, estratificada por grupos y repetida con dos particiones (10 evaluaciones por modelo). La métrica principal es la PR-AUC, porque solo el 17 % de los pedidos son bicicletas y la exactitud (*accuracy*) sería engañosa: predecir siempre «no es bicicleta» acertaría el 83 % sin aportar nada.

4.2 Cómo se leen las métricas

- **ROC-AUC:** probabilidad de que el modelo asigne mayor puntaje a un pedido de bicicleta que a uno que no lo es, tomados al azar. 0.50 es el azar; 1.00, la perfección.

- **PR-AUC:** equilibrio entre precisión y cobertura; su valor de azar es la proporción de bicicletas (0.162).
- **Lift:** cuántas veces más bicicletas hay en un grupo de perfiles que en el promedio.
- **Curva de ganancias:** qué porcentaje de las bicicletas se alcanza contactando solo al *k* % mejor puntuado.

4.3 Arquitectura y reproducibilidad

El flujo está implementado como proyecto **Kedro** ejecutable con `kedro run`: tres pipelines (*data_processing*: limpieza, filtro de catálogo y tabla de modelado; *model_training*: partición por grupos, líneas base, ajuste con Optuna y modelo final; *model_evaluation*: métricas con intervalos, lift, importancia y resumen por segmento), un catálogo de datos y parámetros configurables en YAML. Cada *push* dispara en GitHub Actions la instalación, Ruff, las pruebas (pytest) y una ejecución reducida del pipeline. Repositorio: github.com/JuanDi37/Machine-Learning.

4.4 Ingeniería de variables

Se partió de las cinco variables permitidas. Se probaron tramos de edad, la combinación país–estado, género × tramo de edad, mes cíclico, trimestre y edad × mes. **Ninguna mejoró el modelo** por encima de la variación entre pliegues: los árboles ya construyen internamente esos tramos e interacciones. Se conservaron las cinco variables originales, que coinciden exactamente con lo disponible antes de la compra.

5. Selección del modelo (*Model selection*)

5.1 Algoritmos comparados

Se comparó una línea base (la tasa global), la regresión logística (con y sin interacciones), cuatro implementaciones de *gradient boosting* —HistGradientBoosting, XGBoost [6], LightGBM [7] y CatBoost [8]— y una mezcla de LightGBM y CatBoost. Las redes neuronales no se consideraron: con cinco variables y ~77 mil filas no hay evidencia de que superen a los árboles potenciados en datos tabulares [9].

> **¿Cómo funciona el algoritmo seleccionado?** Un *árbol de decisión* hace preguntas sucesivas («¿edad menor de 25?», «¿país = Canadá?») hasta llegar a una estimación; uno solo es débil. El *gradient boosting* [10] construye cientos de árboles pequeños **en secuencia**: cada árbol nuevo se concentra en corregir los errores que dejó el conjunto anterior, y la predicción final es la suma de todos, convertida en probabilidad. **LightGBM** [7] lo hace de forma muy eficiente (agrupa los valores en histogramas y hace crecer cada árbol por la hoja que más reduce el error) y trata de forma nativa variables con muchos niveles, como el estado, agrupándolos de la mejor manera posible. Para no memorizar el pasado, se limitan el tamaño de las hojas, se penalizan los pesos extremos (regularización L2) y cada árbol usa solo una muestra de filas y de variables.

5.2 Ajuste de hiperparámetros

Los hiperparámetros de LightGBM (número de árboles, tasa de aprendizaje, hojas, regularización, etc.) se ajustaron con **Optuna** [11], que aplica optimización bayesiana (TPE): cada prueba usa lo aprendido en las anteriores para decidir qué configuración probar, de forma más eficiente que una búsqueda en cuadrícula. Se hicieron 60 pruebas sobre una partición de validación distinta de la usada para comparar modelos. La profundidad de CatBoost se ajustó también (4, 6 y 8).

5.3 Resultados de la comparación (validación cruzada, 10 pliegues)

Modelo	ROC-AUC	PR-AUC	Log-loss	Segundos por ajuste
Mezcla LightGBM + CatBoost	0.6625	0.2581	0.4256	26.2
CatBoost	0.6600	0.2567	0.4259	25.4
LightGBM (Optuna) — seleccionado	**0.6612**	**0.2562**	**0.4263**	**0.8**
LightGBM (por defecto)	0.6569	0.2545	0.4277	0.6
HistGradientBoosting	0.6552	0.2521	0.4277	1.3
XGBoost	0.6556	0.2516	0.4283	1.1
Regresión logística + interacciones	0.6218	0.2283	0.4374	0.4
Regresión logística	0.6101	0.2191	0.4396	0.2
Línea base (tasa global)	0.5000	0.1669	0.4509	0.0

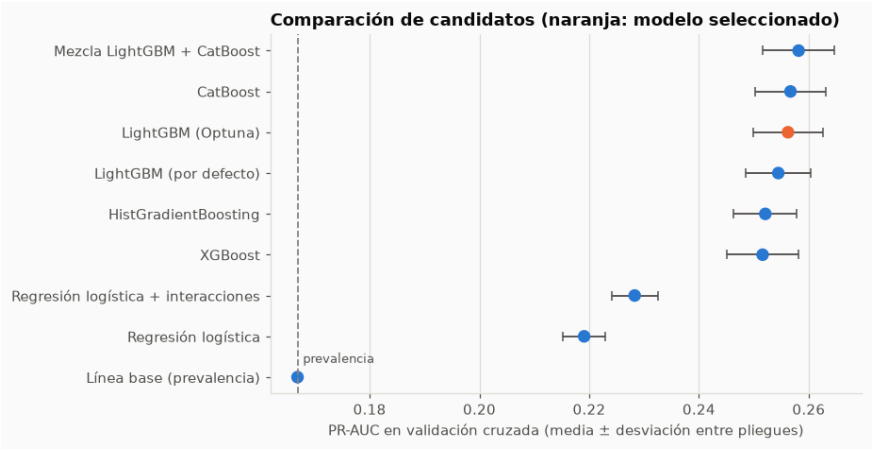


Figura 2. PR-AUC en validación cruzada (media ± desviación entre pliegues).

Criterio de selección (fijado antes de ver los resultados). Se elige el modelo con mayor PR-AUC; si uno más simple o más rápido queda a menos de 0.002 del mejor (menos del 1 % relativo), se prefiere el más simple. La mezcla es la mejor por solo ≈0.002 y CatBoost empata, pero ambos son más de 20 veces más lentos y la mezcla obliga a mantener dos librerías. **LightGBM con Optuna** cumple el criterio: es el más simple y rápido dentro de la tolerancia, predice en milisegundos, está bien calibrado y se explica de forma exacta con SHAP. Los cuatro tipos de *boosting* convergen en el mismo nivel, y superan con claridad a la regresión logística (≈0.03 de PR-AUC): existen interacciones, como edad × mercado, que un modelo lineal no captura.

6. Resultados (*Results*)

6.1 Desempeño en datos no vistos (19,108 pedidos de prueba)

Modelo	ROC-AUC	IC 95 %	PR-AUC	IC 95 %	Log-loss
Línea base (tasa global)	0.500	—	0.162	—	0.443
Regresión logística	0.612	0.600–0.625	0.215	0.206–0.225	0.432
LightGBM (Optuna) — final	**0.665**	**0.654–0.676**	**0.251**	**0.240–0.262**	**0.418**

Los intervalos se obtienen por *bootstrap* por grupos. El modelo mejora a la regresión logística en +0.053 de ROC-AUC (IC 95 %: +0.044 a +0.062) y el resultado en prueba es consistente con la validación cruzada (0.661 ± 0.005), por lo que no hay señales de sobreajuste. Las probabilidades están bien calibradas (error de calibración esperado de 0.007): un puntaje de 25 % corresponde, en la práctica, a una de cada cuatro compras.

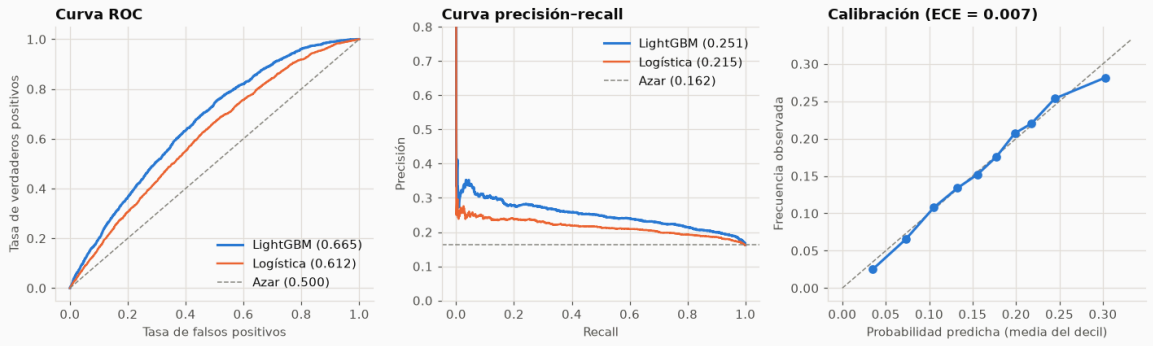


Figura 3. Curvas ROC, precisión–recall y calibración del modelo final en el conjunto de prueba.

6.2 Valor para el negocio: lift y ganancias

Si se contacta al…	% de bicicletas capturadas	% de la ganancia de bicicletas	% al azar	Lift
10 % mejor puntuado	17.3	16.2	10	1.73
20 % mejor puntuado	33.0	31.1	20	1.65
30 % mejor puntuado	**46.5**	**46.6**	**30**	**1.55**
40 % mejor puntuado	59.3	60.3	40	1.48
50 % mejor puntuado	70.2	70.7	50	1.40

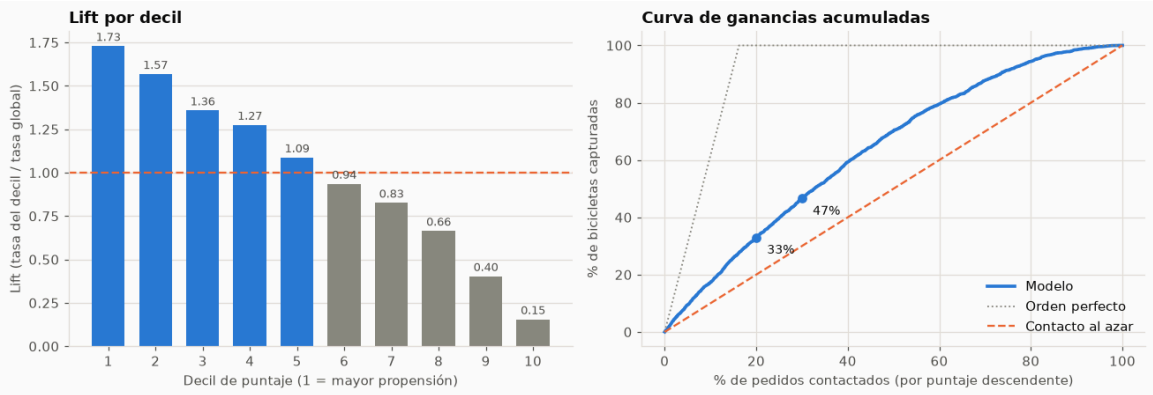


Figura 4. Izquierda: lift por decil de puntaje (1 = mayor propensión). Derecha: porcentaje de bicicletas capturadas al contactar a los perfiles mejor puntuados.

6.3 ¿Qué variables importan y en qué sentido?

La **edad** es la variable más influyente (su permutación reduce el ROC-AUC en 0.099), seguida del **estado** (0.062) y el **mes** (0.036); el país (0.018) y el género (0.007) aportan menos. Los valores SHAP [12] muestran la dirección: la propensión es baja en los menores de 25 años, máxima entre los 27 y los 45 y cae a partir de los 55; Canadá y, en menor medida, Estados Unidos reducen la probabilidad, mientras que Alemania, Reino Unido, Francia y Australia la aumentan; noviembre y diciembre son los meses más favorables y el género casi no pesa. Estos patrones coinciden con la exploración descriptiva, lo que indica que el modelo aprendió regularidades reales.

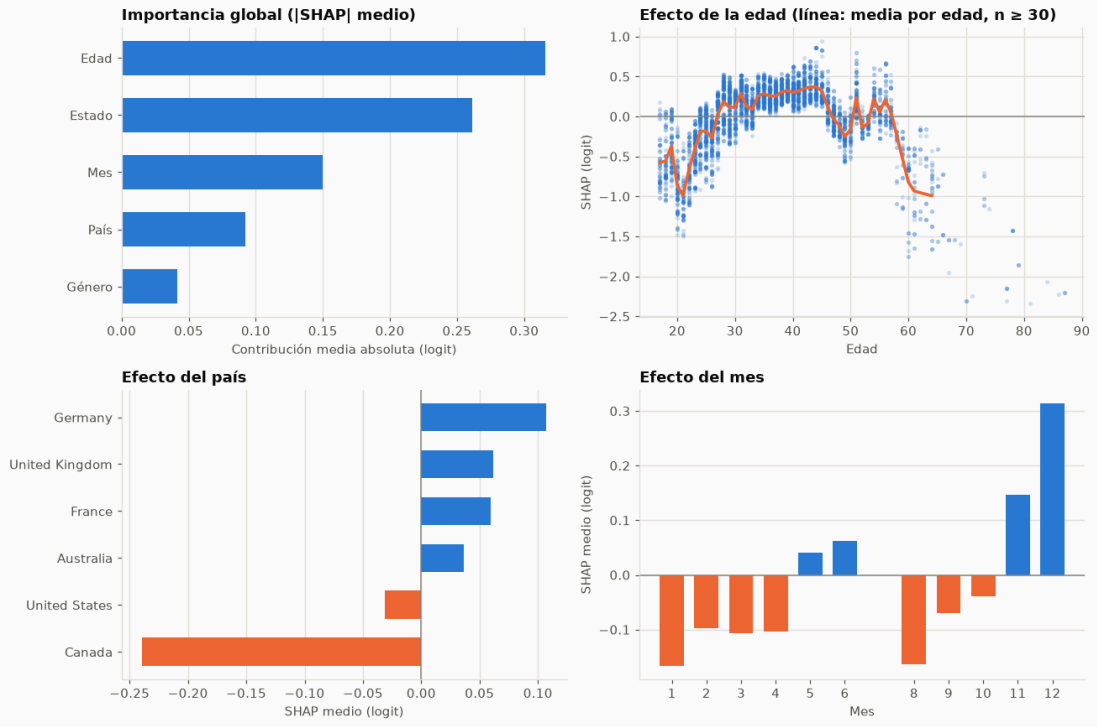


Figura 5. Interpretación con SHAP: importancia global y efecto de la edad, el país y el mes (valores positivos aumentan la probabilidad de bicicleta).

7. Interpretación de negocio (*Business interpretation*)

7.1 Por edad

Tramo	Pedidos	% bicicleta	% accesorios	% ropa	Ganancia media por pedido	% de la ganancia que aportan las bicicletas
< 25	15,154	12.1	71.5	16.4	$187	45.2
25–34	**32,614**	**18.1**	**65.2**	**16.8**	**$230**	**52.5**
35–44	**27,050**	**19.1**	**65.0**	**15.9**	**$257**	**55.7**
45–54	15,057	15.7	68.0	16.4	$233	48.8
55+	6,484	11.4	71.9	16.7	$217	38.8

Los clientes de **25 a 44 años** son el núcleo del negocio de bicicletas: compran la mayor proporción de bicicletas, dejan la mayor ganancia por pedido y las bicicletas aportan más de la mitad de su ganancia. Los menores de 25 y los mayores de 55 compran proporcionalmente más accesorios y ropa.

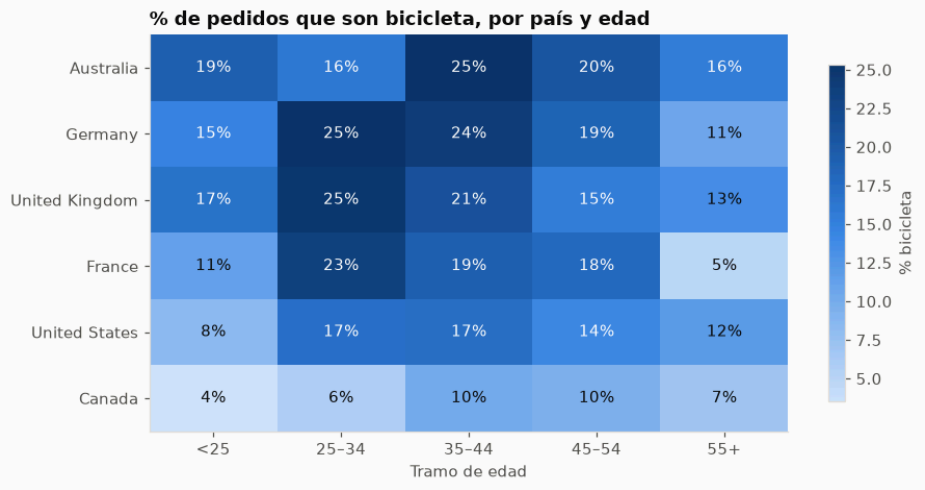


Figura 6. Porcentaje de pedidos que son bicicleta por país y tramo de edad (celdas con al menos 200 pedidos).

7.2 Por mercado y geografía

Alemania (21.8 %), Reino Unido, Australia y Francia superan el promedio (16.6 %); Estados Unidos (15 %) queda algo por debajo y **Canadá (7.4 %)** muy por debajo en todas las edades. En Alemania, Reino Unido y Francia el máximo se da entre los 25 y 34 años (23–25 %); en Australia, entre los 35 y 44 (25 %). Dentro de los países hay dispersión: entre los estados con al menos 500 pedidos, Bayern (≈24 %), Saarland, South Australia, Hessen y Hamburg lideran; British Columbia (≈7 %), Oregon y Washington cierran la lista (véase el cuaderno, sección 4.3).

7.3 Por género

La diferencia global entre mujeres (16.8 %) y hombres (16.4 %) es de 0.4 puntos porcentuales y **no es estadísticamente significativa**. Dentro de algunos tramos aparecen diferencias pequeñas: entre los menores de 25 años los hombres compran más bicicletas (13.3 % frente a 10.6 %), mientras que entre 35–44 y 55+ las mujeres compran algo más (+2.0 y +2.4 puntos). Al tratarse de muchas comparaciones, algunas de esas diferencias pueden ser azar, y su magnitud es pequeña comparada con la de la edad o el país.

7.4 Perfiles de mayor y menor propensión (≥ 300 pedidos)

Mayor propensión	Tasa	Lift
Alemania · 25–34 · mujeres	26.5 %	1.60
Alemania · 35–44 · mujeres	25.6 %	1.54
Australia · 35–44 · hombres	25.5 %	1.54
Australia · 35–44 · mujeres	25.2 %	1.52
Reino Unido · 25–34 · hombres	24.8 %	1.50
Reino Unido · 25–34 · mujeres	24.6 %	1.48

Menor propensión	Tasa	Lift
Canadá · <25 · mujeres	2.7 %	0.16
Canadá · <25 · hombres	4.2 %	0.25
Canadá · 55+ · hombres	4.9 %	0.30
Canadá · 25–34 · mujeres	5.0 %	0.30
EE. UU. · <25 · mujeres	6.4 %	0.38
Canadá · 25–34 · hombres	6.6 %	0.40

8. Recomendaciones (*Recommendations*)

1. **Priorizar con el puntaje, sin excluir.** Dirigir la primera ola de campañas de bicicletas al 20–30 % de perfiles mejor puntuados: capturan el 33–46 % de las compras de bicicleta, frente al 20–30 % al azar. Equivale a llegar a los mismos compradores contactando a un 36 % menos de perfiles.
2. **Por edad:** concentrar la oferta de bicicletas en el tramo de **25 a 44 años**; para menores de 25 y mayores de 55 priorizar accesorios, ropa o productos de entrada, con mensajes específicos.
3. **Por mercado:** reforzar bicicletas en **Alemania, Reino Unido, Francia y Australia** (25–34 años en las tres primeras; 35–44 en Australia). En **Canadá** y, en menor medida, **Estados Unidos**, la propensión es baja en todas las edades: investigar la

causa (precio, canal, oferta local) antes de invertir en campañas de bicicletas.

4. **Por geografía fina:** usar los estados de mayor tasa (Bayern, Saarland, South Australia, Hessen, Hamburg) como pilotos, y revisar los de menor (British Columbia, Oregon, Washington).
5. **Por época del año:** programar campañas de bicicletas hacia noviembre–diciembre y mayo–junio, que muestran la mayor propensión; es un indicio, pues solo se observa un ciclo anual.
6. **Por género: no segmentar el presupuesto por género** (diferencia global no significativa). Puede orientar el mensaje creativo dentro de un tramo de edad, nunca para excluir clientes.
7. **Validar antes de escalar:** realizar un piloto A/B (grupo de alto puntaje frente a un grupo de control) para medir el efecto incremental y el retorno reales.
8. **Mejorar los datos:** capturar un identificador de cliente, su historial de compras y el canal permitiría pasar de la propensión por perfil a la propensión por cliente, el mayor salto de desempeño disponible.

9. Limitaciones (*Limitations*)

- **Poder predictivo moderado.** El ROC-AUC de 0.665 indica que el modelo *ordena* perfiles, no que adivine compras individuales. Cuatro algoritmos distintos llegan al mismo nivel: el límite es la información (cinco variables de perfil), no el modelo.
- **Asociación, no causalidad.** Los resultados describen quién ya compró bicicletas, no cuánto aumentarían las ventas por una campaña; eso requiere una prueba A/B o un modelo de *uplift*. No se estima un retorno en dinero porque el dataset no contiene costos de campaña ni tasas de respuesta.
- **Unidad de análisis y repetición.** Cada fila es un pedido, no un cliente, y todos los grupos de pedidos reaparecen en un segundo año con cantidades distintas, un patrón compatible con datos extendidos o replicados. La información independiente es menor que el número de filas, por lo que las particiones se hicieron por grupos.
- **Cobertura temporal.** Tras excluir los meses con catálogo en transición queda un solo ciclo de cada mes (y falta julio): la estacionalidad es un indicio. Los resultados valen para el régimen de catálogo completo.
- **Estados pequeños.** 30 de 51 estados tienen menos de 500 pedidos; sus efectos son inciertos.
- **Sesgo y equidad.** Edad y género son atributos personales. Sirven para orientar *qué ofrecer*, no para excluir clientes, fijar precios ni limitar el acceso a productos; recomendar accesorios a los mayores de 55 no equivale a negarles bicicletas. Conviene revisar la normativa de elaboración de perfiles aplicable en cada país (p. ej., RGPD).
- **Deriva y comparaciones múltiples.** Las preferencias y el catálogo cambian: se debe monitorear calibración y lift y reentrenar periódicamente. Las tablas por segmento contienen muchas comparaciones y deben leerse como guía exploratoria.

10. Conclusión (*Conclusion*)

Solo con la edad, el género, el país, el estado y el mes es posible ordenar los pedidos por su probabilidad de ser una bicicleta de forma claramente mejor que el azar (ROC-AUC 0.665; lift de 1.7 en el decil superior; 46.5 % de las bicicletas con el 30 % de los contactos). El modelo seleccionado, LightGBM ajustado con Optuna, es el más simple y rápido entre los de mejor desempeño, está bien calibrado y es explicable. La edad y la geografía concentran la señal: la oferta de bicicletas rinde más en clientes de 25 a 44 años de Alemania, Reino Unido, Francia y Australia, mientras que Canadá, Estados Unidos y los extremos de edad se sirven mejor con accesorios y ropa; el género no justifica segmentar el presupuesto. Como siguiente paso se recomienda validar la priorización con un piloto A/B y enriquecer los datos con historial por cliente.

Referencias

[1] Chapman, P., et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium.

[2] Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 15.

[3] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10*(3), e0118432.

[4] Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.

[5] Bhatti, J. (s. f.). *Sales Data* [conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/jehanzaibbhatti/sales-data

[6] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of KDD 2016*, 785–794.

[7] Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*.

[8] Prokhorenkova, L., et al. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems, 31*.

[9] Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems, 35*.

[10] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232.

[11] Akiba, T., et al. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of KDD 2019*, 2623–2631.

[12] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*.