¿A qué perfiles dirigir las ventas de bicicletas?

Machine Learning for Business · Proyecto 1 · Dataset: Sales Data (Kaggle) · Juan Diego Letona y Jose Tanchez

0.665 ROC-AUC en datos no vistos (azar 0.50)

1.7× lift del 10 % mejor puntuado

46.5 % de las bicicletas con el 30 % de contactos

? Problema y pregunta

Las bicicletas son el **17 % de los pedidos** pero generan el **51 % de la ganancia**. Marketing debe decidir a quién ofrecérselas con presupuesto limitado.

> **Pregunta:** conociendo solo edad, género, país, estado y mes, ¿qué probabilidad hay de que un pedido sea una bicicleta?

Sin fuga: se excluyen producto, precio, costo, cantidad, ingreso y ganancia.

▦ Datos

113 mil	96,359	5
pedidos 2011–2016	pedidos analizados	variables de perfil

- Sin faltantes; 1,000 duplicados eliminados; solo 22 meses con catálogo completo.
- Pedidos «gemelos» entre años: partición **por grupos**.

⚙ Metodología (CRISP-DM)

Limpieza › Partición 80/20 por grupos › 9 modelos en CV › Optuna (60 pruebas) › **Prueba única + SHAP**

Métrica principal: **PR-AUC**; intervalos por *bootstrap* de grupos.

! Limitaciones

- Poder moderado: solo 5 variables de perfil.
- Asociación, no causalidad: validar con prueba A/B.
- Un ciclo anual por mes; filas = pedidos, no clientes.
- Edad y género orientan la oferta, nunca excluyen.

★ Modelo seleccionado: LightGBM + Optuna

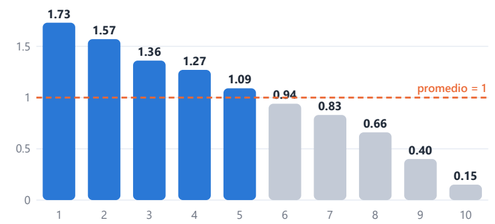
Cientos de árboles pequeños en secuencia, cada uno corrige los errores del anterior. Rápido, bien calibrado y explicable con SHAP. Entre modelos a menos de 0.002 de PR-AUC se eligió el más simple.

PR-AUC en validación cruzada (10 pliegues)

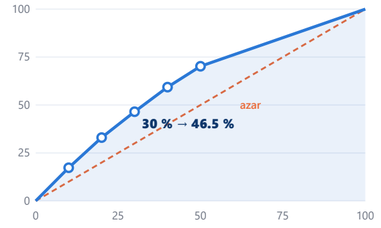


↗ Resultados en datos no vistos (19,108 pedidos)

Lift por decil de puntaje (1 = mayor propensión)



% de bicicletas capturadas vs. % contactado



ROC-AUC 0.665 (IC 95 %: 0.654–0.676) vs 0.612 de la regresión logística · **PR-AUC 0.251** vs 0.162 del azar. Edad, estado y mes concentran la señal; el género casi no pesa.

% Propensión por país y edad (% de pedidos que son bicicleta)

	<25	25–34	35–44	45–54	55+
Australia	19%	16%	25%	20%	16%
Alemania	15%	25%	24%	19%	11%
Reino Unido	17%	25%	21%	15%	13%
Francia	11%	23%	19%	18%	5%
EE. UU.	8%	17%	17%	14%	12%
Canadá	4%	6%	10%	10%	7%

- **25–44 años** es el núcleo: 18–19 % de bicicletas y $230–257 por pedido.
- **Canadá (7 %)** y EE. UU. (15 %) quedan bajo el promedio de 16.6 %.
- Género: diferencia global de 0.4 pp, no significativa.

✓ Recomendaciones

1. **Priorizar con el puntaje** al 20–30 % de perfiles: mismos compradores con 36 % menos contactos.
2. **Bicicletas a 25–44 años** en Alemania, Reino Unido, Francia (25–34) y Australia (35–44).
3. **Accesorios y ropa** para menores de 25, mayores de 55, Canadá y EE. UU.
4. **Campañas** en nov–dic y may–jun (indicio: un solo ciclo anual).
5. **No segmentar el presupuesto por género.**
6. **Piloto A/B** antes de escalar; capturar ID de cliente e historial.

Arquitectura de la solución

sales_data.csv (data/01_raw) › data_processing (limpieza · catálogo estable · tabla de modelado) › model_training (partición · baselines · Optuna · LightGBM) › model_evaluation (métricas · lift · permutación · segmentos) › data/08_reporting (metrics.json · tablas · gráficos)

Kedro (`kedro run`) · catálogo y parámetros YAML
GitHub Actions: Ruff · pytest · kedro run