¿A quién dirigir la campaña de bicicletas?

Modelo de propensión de compra con gradient boosting · Dataset *Sales Data* (Kaggle) · 106,701 pedidos, 6 países

Machine Learning for Business · Proyecto 1 · 2026
Juan Diego Letona (20230285) · Jose Tanchez (20230005)

1 Problema de negocio

Stakeholder: Gerencia de Marketing / Ventas Regionales.

Pregunta: dado el perfil de un cliente (edad, género, ubicación) y el mes, ¿qué probabilidad hay de que compre una **bicicleta**, y qué perfiles conviene priorizar?

Por qué importa: las bicicletas son el **19 %** de los pedidos pero el **56 %** de la ganancia ($713 por pedido vs. $127 en accesorios).

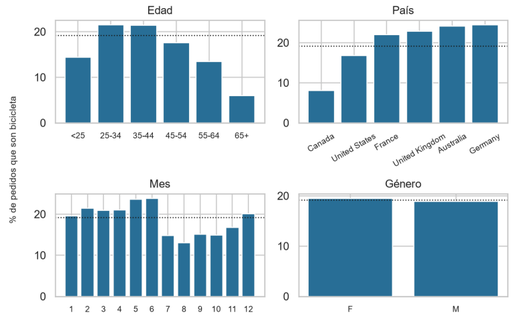
Objetivo y éxito: clasificación binaria (probabilidad para ordenar perfiles); ROC/PR-AUC sobre la línea base y % de compras capturadas con el top-*k* %.

2 Datos

113,036 filas × 18 columnas (2011–2016). **Sin ID de cliente**: cada fila es una transacción.

- **0** faltantes · **1,000** duplicados exactos eliminados
- Atípicos (edad hasta 87; bicicletas caras) **conservados**: son ventas reales
- 2011–2012 = 100 % bicicletas → **excluidos**
- Años que repiten el 100 % de las llaves de otros años → **partición por grupos** para evitar fuga
- Solo variables **previas a la compra**: edad, género, país, estado, mes

3 Quién compra bicicletas



Mayor propensión a 25–44 años y en Alemania/Australia; muy baja en Canadá y >64 años. El género no discrimina.

4 Metodología (CRISP-DM) y arquitectura

data_processing limpieza, duplicados, features, grupos → **model_training** split por grupos, baselines, búsqueda aleatoria (25 conf.) → **model_evaluation** métricas + IC, lift, ganancias, importancia, gráficos

Kedro (`catalog.yml`, `parameters.yml`, `kedro run`) · **GitHub Actions**: Ruff + pytest + pipeline en cada *push* · validación cruzada agrupada 5-fold · 80/20 por grupos · IC por *bootstrap*

5 Modelo seleccionado y resultados

HistGradientBoostingClassifier (scikit-learn): rápido (~1 min), categorías nativas, explicable. No se eligió solo por la métrica: la regresión logística (alternativa transparente) queda ≈5 puntos de AUC abajo.

0.661 ROC-AUC · IC95 %: 0.650–0.671

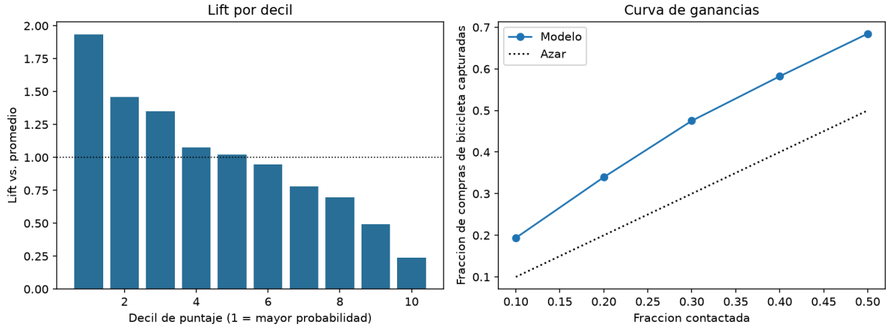
0.293 PR-AUC (azar: 0.185)

1.9× lift del decil superior

48 % de compras con 30 % de contactos

Prueba (n = 21,249)	ROC-AUC	PR-AUC	Brier
Baseline: prevalencia	0.500	0.185	0.151
Regresión logística	0.612	0.248	0.147
Gradient boosting (final)	**0.661**	**0.293**	**0.144**

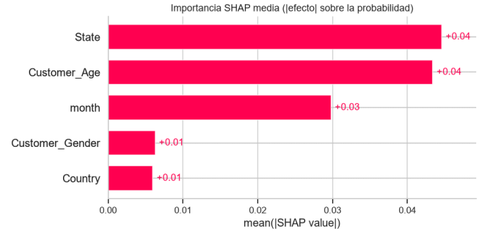
6 Valor de negocio: lift y curva de ganancias



7 Recomendaciones

- **Priorizar, no excluir:** primera ola al 20–30 % mejor puntuado (captura 34–48 % de las compras vs. 20–30 % al azar).
- **Foco:** 25–44 años; South Australia, Bayern, Hamburg, Hessen. Probar accesorios o mensajes distintos en Canadá, EE. UU. y >64 años.
- **No segmentar por género** (aporte nulo).
- **Piloto A/B** antes de escalar para medir efecto real y ROI.
- **Revisar precios por país:** ingreso/precio de lista ≈1 % menor en Canadá vs. ≈16 % en Australia (causa no documentada).

8 Qué explica la predicción



Estado, edad y mes concentran la señal (SHAP e importancia por permutación coinciden).

! Limitaciones

- Señal **moderada** (AUC 0.66): ordena, no adivina individuos.
- Datos con rasgos artificiales; sin ID de cliente; catálogo cambia en jul-2013 (afecta el mes).
- Resultado **observacional**, no causal. Riesgo de discriminar si se usa para excluir.
- Calibración algo sobreconfiada en el tramo alto.

Referencias

Chapman et al. (2000) *CRISP-DM 1.0* · Friedman (2001) *Ann. Statist.* 29(5) · Ke et al. (2017) LightGBM, *NeurIPS* · Pedregosa et al. (2011) scikit-learn, *JMLR* 12 · Kaufman et al. (2012) Leakage, *ACM TKDD* 6(4) · Saito & Rehmsmeier (2015) *PLoS ONE* · Bergstra & Bengio (2012) *JMLR* 13 · Lundberg & Lee (2017) SHAP, *NeurIPS* · Breiman (2001) *Mach. Learn.* 45 · Fisher et al. (2019) *JMLR* 20 · Niculescu-Mizil & Caruana (2005) *ICML* · Provost & Fawcett (2013) *Data Science for Business* · Efron & Tibshirani (1993) *Bootstrap* · Datos: Kaggle, jehanzaibbhatti/sales-data · Kedro (docs.kedro.org) · Ruff (docs.astral.sh/ruff).