¿A quién dirigir la campaña de bicicletas?

Machine Learning for Business · Proyecto 1 · Facultad de Ciencias Económicas · 2026
Autores: Juan Diego Letona (20230285) y Jose Tanchez (20230005) · Dataset 2: *Sales Data* (Kaggle)

1. Introduction

Una empresa que vende bicicletas, accesorios y ropa de ciclismo en seis países debe decidir a quién dirigir sus campañas con un presupuesto limitado. Las bicicletas son solo el 19 % de los pedidos, pero generan el 56 % de la ganancia (figura 1), así que atraer al cliente correcto importa. Este proyecto construye un modelo de *Machine Learning* que estima, a partir del perfil del cliente, qué tan probable es que su compra sea una bicicleta, y lo traduce en una lista de prioridades. Se siguió la metodología CRISP-DM de seis fases (comprensión del negocio, de los datos, preparación, modelado, evaluación y despliegue) [1].

2. Business problem

Elemento	Descripción
Contexto	Venta de bicicletas y accesorios en EE. UU., Australia, Canadá, Reino Unido, Alemania y Francia.
Stakeholder	Gerencia de Marketing / Ventas Regionales: decide a qué perfiles y mercados dirigir campañas de bicicletas.
Pregunta	Dado el perfil de un cliente (edad, género, ubicación) y el mes, ¿qué probabilidad hay de que compre una bicicleta y qué perfiles conviene priorizar?
Objetivo analítico	Clasificación binaria (*¿bicicleta, sí/no?*) que entrega una probabilidad para ordenar perfiles.
Métricas de éxito	Técnica: ROC-AUC y PR-AUC mayores que la línea base en datos no vistos [2]. Comercial: % de compras de bicicleta capturadas al contactar solo al *k* % mejor puntuado, frente al azar (curva de ganancias) [3].
Impacto	Focalizar el primer contacto en los perfiles de mayor puntaje: con el 30 % de los contactos se alcanza ≈48 % de las compras de bicicleta (30 % al azar). No se estima ROI en dólares: el dataset no incluye costos de campaña ni tasas de respuesta.

> **Pendiente administrativo:** la guía exige que el profesor apruebe la pregunta de negocio antes del desarrollo; esta propuesta debe someterse a aprobación.

3. Data

Fuente. *Sales Data*, Kaggle (enlace entregado en la guía del curso) [4]: 113,036 filas y 18 columnas (fecha, edad y género del cliente, país, estado, producto, cantidad, costo, precio, ingreso y ganancia), 2011–2016. **No existe identificador de cliente**: cada fila es una transacción.

Calidad y decisiones (el detalle y el código están en el notebook):

Hallazgo	Evidencia	Decisión
Valores faltantes	0 en todas las columnas	No se imputa.
Duplicados	1,000 filas idénticas (0.9 %); quedan 112,036	Se eliminan.
Consistencia	`Cost = costo unitario × cantidad` y `Profit = ingreso − costo` en el 100 % de filas	Sin correcciones.

Atípicos	Edades hasta 87 años (526 fuera de 1.5×IQR [5]); 58 ganancias negativas; ganancias altas = bicicletas caras	Se conservan: son ventas reales; los árboles son robustos a extremos.
2011–2012	100 % bicicletas	Se excluyen (objetivo constante). Quedan 106,701 filas.
Registros "gemelos"	El 100 % de las llaves (día, mes, edad, género, estado, producto) de 2012, 2015 y 2016 ya existen en 2011, 2013 y 2014, con cantidades distintas	Patrón consistente con datos extendidos artificialmente (origen no documentado). Se usa partición por grupos para evitar fuga [6].
Cambio de catálogo	Accesorios y Ropa solo existen desde jul-2013 (antes: 100 % bicicletas); en jul-2014 no hay bicicletas	No se pronostican series. Se conservan esos meses (≈7 % de las filas); un chequeo con ventana estricta deja el AUC igual (0.66). El efecto del mes se interpreta con cautela.

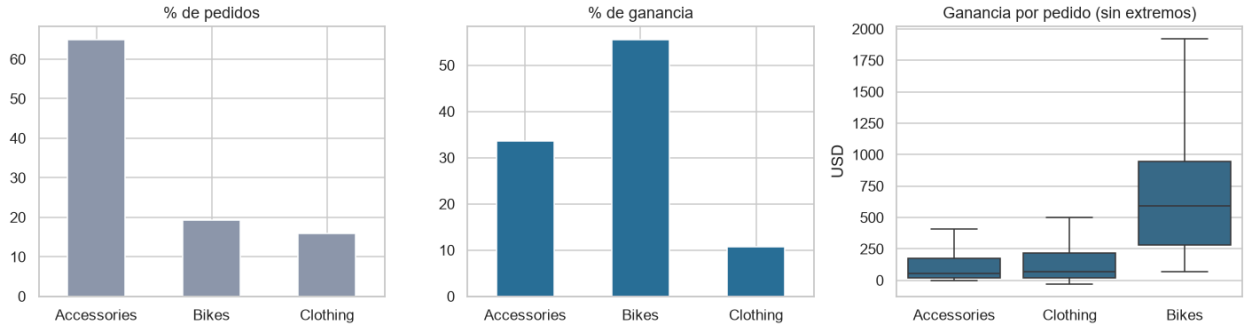


Figura 1. Las bicicletas son ≈19 % de los pedidos pero ≈56 % de la ganancia; cada una deja en promedio $713 frente a $127 de un pedido de accesorios.

4. Methods

- **Variables.** Solo lo que se conoce antes de la compra: edad, género, país, estado y mes. Se excluyeron producto, precios, costos, cantidad, ingreso y ganancia porque determinan o resultan de la categoría comprada (*fuga de información*) [6]. Se probaron día de la semana y del mes, y se descartaron: sin ellas el resultado es igual o mejor.
- **Validación.** 80 % entrenamiento / 20 % prueba por grupos (los registros gemelos nunca quedan separados) y validación cruzada agrupada de 5 pliegues. El conjunto de prueba solo se usa para reportar. Intervalos de confianza por *bootstrap* de grupos [7].
- **Línea base.** (a) Predecir siempre la prevalencia (19 %); (b) regresión logística, un modelo simple e interpretable.
- **Ajuste.** Búsqueda aleatoria de 25 configuraciones de hiperparámetros [8], optimizando PR-AUC.
- **Interpretación.** Importancia por permutación [9, 10], SHAP [11] y gráficos de dependencia parcial [12].
- **Ingeniería.** Proyecto Kedro con tres pipelines (limpieza → entrenamiento → evaluación), `catalog.yml` y `parameters.yml` [13]; GitHub Actions con Ruff [14], pruebas y `kedro run` en cada *push*.

5. Model selection

Se eligió el **gradient boosting de histogramas** (`HistGradientBoostingClassifier`, scikit-learn [15]) porque (i) el *boosting* sobre árboles es el estándar práctico en datos tabulares con variables mixtas [12, 16]; (ii) maneja categorías (estados) y valores desconocidos sin transformaciones pesadas; (iii) entrena en segundos con 100 mil filas; y (iv) se interpreta con herramientas estándar. La regresión logística queda como alternativa si se prioriza transparencia total. Random forest y redes neuronales no se probaron: es una justificación *a priori*, no un resultado empírico. En un experimento adicional (`notebooks/experimento_lightgbm.ipynb`, mismos pliegues agrupados)

sí se compararon LightGBM [19] con 60 intentos de búsqueda bayesiana [20] y CatBoost [21]: ninguno mejora el AUC de forma distinguible del ruido (diferencias de −0.001 a +0.002 en prueba; IC95 % que incluyen 0); una mezcla de los tres sube la PR-AUC ≈0.007 (de 0.250 a 0.257 en esa prueba), una mejora pequeña que no justifica la complejidad adicional. **El modelo no se eligió solo por la métrica**: la diferencia con la regresión logística es de ≈5 puntos de AUC, a cambio de un modelo algo menos transparente pero explicable y barato de entrenar.

Hiperparámetros elegidos: tasa de aprendizaje 0.091, 497 iteraciones, 46 hojas máximas, profundidad 6, mínimo 302 muestras por hoja, regularización L2 = 1.10. Las 25 configuraciones dieron PR-AUC entre 0.288 y 0.295 en validación: el límite lo pone la señal disponible, no el ajuste.

6. Results

0.661	**0.293**	**1.9×**	**48 %**
ROC-AUC (IC 95 %: 0.650–0.671)	PR-AUC (azar: 0.185)	Lift del decil superior	Compras capturadas con el 30 % de contactos

Modelo (conjunto de prueba, n = 21,249)	ROC-AUC	PR-AUC	Brier
Línea base: prevalencia	0.500	0.185	0.151
Regresión logística	0.612	0.248	0.147
Gradient boosting (final)	**0.661**	**0.293**	**0.144**

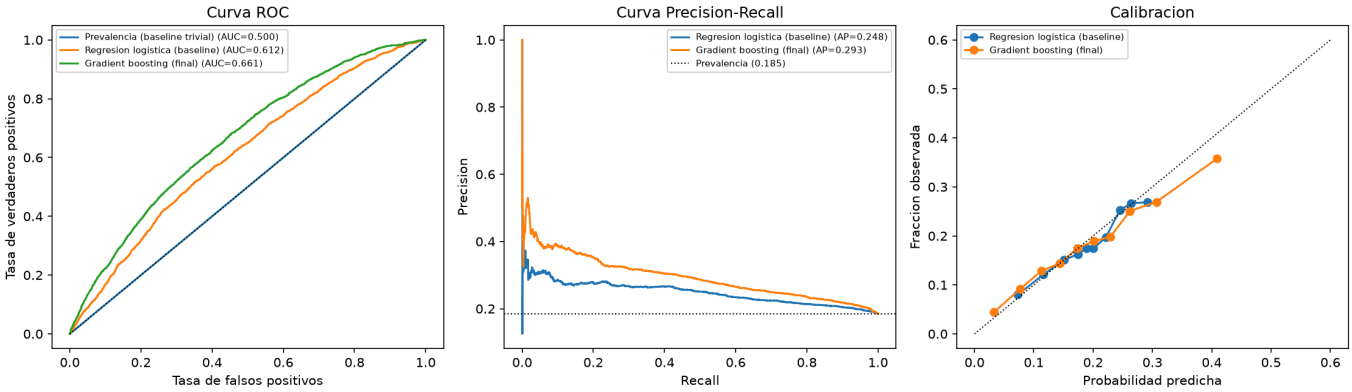


Figura 2. Curvas ROC, precisión-recall y calibración en el conjunto de prueba. Las probabilidades están bien calibradas [18], con ligera sobreconfianza en el tramo más alto (≈0.41 predicho vs. ≈0.36 observado).

Contactos (top % del puntaje)	Compras de bicicleta capturadas	(Azar)	Ganancia total capturada
10 %	19 %	10 %	13 %
20 %	34 %	20 %	26 %
30 %	**48 %**	**30 %**	**37 %**
50 %	68 %	50 %	58 %

El 10 % de pedidos con mayor puntaje compra bicicleta en el 35.8 % de los casos (1.9× el promedio de 18.5 %); el 10 % de menor puntaje, solo en el 4.4 % (0.24×). La mejora sobre las líneas base es clara (la regresión logística, 0.612, queda fuera del IC del modelo final), pero el poder discriminativo es **modesto**: con solo edad, lugar y mes no se puede "adivinar" una compra individual.

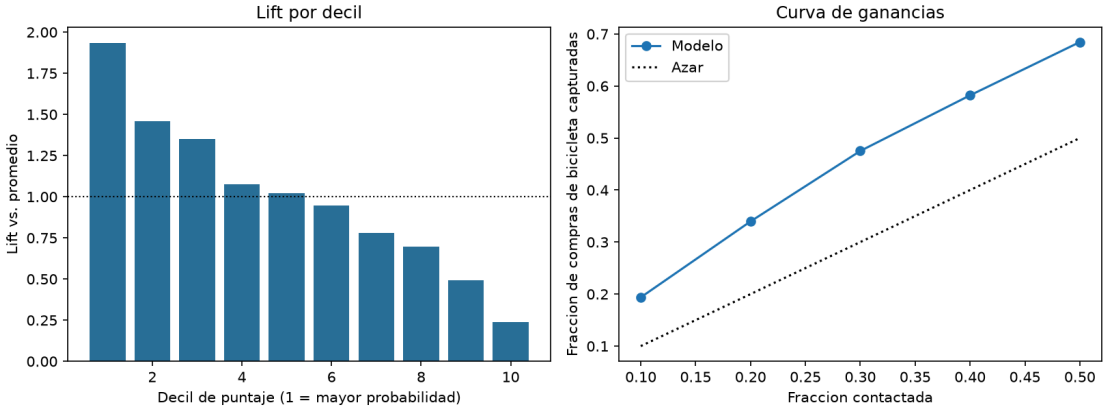


Figura 3. Lift por decil y curva de ganancias (resultados observacionales sobre pedidos de prueba).

7. Business interpretation

Estado, edad y mes concentran casi toda la señal; país y género aportan muy poco (figura 4). La propensión es mayor entre 25 y 44 años y cae después de los 55; los mayores de 64 años compran bicicletas en solo el 6 % de sus pedidos. Por mercado: Alemania (24.4 %), Australia (24.1 %), Reino Unido (22.8 %) y Francia (22.0 %) superan el promedio de 19.2 %; EE. UU. (16.8 %) y sobre todo Canadá (8.0 %) quedan por debajo. Entre los estados con al menos 500 pedidos destacan South Australia (29.1 %), Bayern, Hamburg y Hessen (≈25 %); British Columbia (8.0 %), Oregon (15.1 %) y Washington (15.6 %) son los más bajos. La propensión es más alta de enero a junio y diciembre que de julio a noviembre, aunque este patrón está parcialmente contaminado por el lanzamiento del catálogo en julio de 2013 (sección 3).

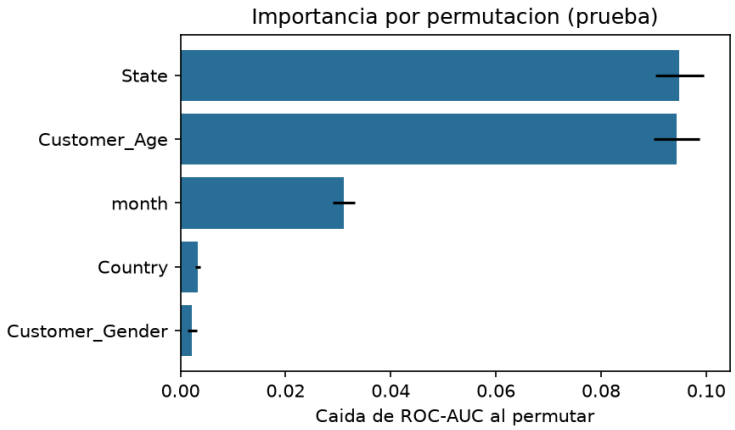


Figura 4. Importancia de cada variable (caída de ROC-AUC al barajarla), conjunto de prueba.

8. Recommendations

1. **Priorizar, no excluir.** Concentrar la primera ola de la campaña de bicicletas en el 20–30 % de perfiles mejor puntuados (captura 34–48 % de las compras de bicicleta frente a 20–30 % al azar).
2. **Enfocar por edad y ubicación:** 25–44 años y estados como South Australia, Bayern, Hamburg y Hessen. En Canadá y EE. UU., y entre mayores de 64, probar otros productos (accesorios/ropa) o mensajes distintos.
3. **No segmentar por género:** su aporte predictivo es prácticamente nulo.
4. **Hacer un piloto A/B** (grupo de alto puntaje con campaña vs. control) para medir el efecto real y el ROI antes de escalar: este modelo solo describe asociaciones históricas.
5. **Revisar la política de precios por país:** el ingreso por unidad es sistemáticamente menor al precio de lista (≈1 % en Canadá vs. ≈16 % en Australia). No sabemos si son descuentos, tipo de cambio o precios locales: el área comercial debe aclararlo.

9. Limitations

- **Señal moderada** (AUC 0.66): ordena mejor que el azar, no predice individuos. Para mejorar harían falta variables de comportamiento (historial, ingresos, canal).
- **Sin ID de cliente:** no se modelan clientes ni historiales; un mismo cliente puede aparecer varias veces.
- **Datos con rasgos artificiales:** duplicados inyectados, cambio de catálogo durante el periodo y registros repetidos entre años. Las conclusiones valen para este dataset; aplicarlas a una empresa real requiere datos reales.
- **Efecto del mes parcialmente contaminado por el cambio de catálogo (jul-2013);** la curva por edad es irregular en edades con pocos pedidos (ruido).
- **Riesgo ético:** usar edad, género o ubicación para *negar* ofertas podría ser discriminatorio o desfavorecer mercados pequeños. El uso recomendado es solo priorizar.
- **Observacional, no causal;** calibración ligeramente sobreconfiada en el tramo alto; el modelo debe reentrenarse si cambia el mix de productos o mercados.
- **Alcance de la verificación:** los resultados se generaron ejecutando el pipeline en una sola máquina; no hubo validación externa.

10. Conclusion

Con solo cinco variables de perfil y contexto, un *gradient boosting* validado sin fuga de información logra priorizar clientes: contactando al 30 % mejor puntuado se alcanza ≈48 % de las compras de bicicleta y ≈37 % de la ganancia. Es un resultado modesto pero honesto, reproducible con `kedro run` y con límites explícitos. El siguiente paso recomendado es un piloto A/B para convertir esta priorización en un efecto medido sobre las ventas.

References

[1] Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium.

[2] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

[3] Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.

[4] Bhatti, J. (s. f.). *Sales Data* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/jehanzaibbhatti/sales-data (enlace de la guía del curso).

[5] Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

[6] Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 15. https://doi.org/10.1145/2382577.2382579

[7] Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

[8] Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*, 281–305.

[9] Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

[10] Fisher, A., Rudin, C., & Dominici, F. (2019). All models are wrong, but many are useful. *Journal of Machine Learning Research, 20*(177), 1–81.

[11] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*. arXiv:1705.07874.

[12] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451 (introduce también la dependencia parcial).

[13] Kedro. (s. f.). *Kedro documentation*. https://docs.kedro.org

[14] Astral. (s. f.). *Ruff documentation*. https://docs.astral.sh/ruff/

[15] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

[16] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*.

[19] Ke, G., et al. (2017), ver [16]. LightGBM: documentación en https://lightgbm.readthedocs.io

[20] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD Conference (KDD)*, 2623–2631.

[21] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems, 31*.

[18] Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd ICML*, 625–632.

Nota: los datos bibliográficos deben verificarse contra la fuente original antes de entregar; solo CRISP-DM se confirmó con una búsqueda en línea durante la elaboración. Todas las cifras provienen de la ejecución del pipeline (`data/08_reporting/`) y del notebook `analisis_completo.ipynb`.