Facultad de Ciencias Económicas
Machine Learning for Business
2026

Proyecto 1
Machine Learning aplicado a un problema de negocio

El objetivo de este proyecto es aplicar un modelo de **Machine Learning** para responder una **pregunta de negocio** concreta y generar recomendaciones útiles para un stakeholder. Fecha de Entrega miercoles 28 de Octubre 1:00 PM en MiU. (Presentación de resultados el mismo día).

El proyecto debe desarrollarse siguiendo la metodología **CRISP-DM** vista en clase, abarcando el ciclo completo de una solución de datos: desde la comprensión del problema de negocio y la construcción del modelo, hasta su implementación reproducible y la comunicación de resultados a una audiencia no técnica.

Objetivos

Al finalizar el proyecto, deberán ser capaces de:

- Traducir una pregunta de negocio en un objetivo analítico con una métrica de éxito medible.
- Seleccionar, entrenar y evaluar un modelo, justificando la elección con datos y criterios de negocio.
- Organizar el trabajo como un proyecto Kedro reproducible y automatizar su validación con GitHub Actions.
- Comunicar resultados, recomendaciones y limitaciones a una audiencia no técnica.

Dataset

Para este proyecto se utilizarán los siguientes datasets. El proyecto se realizará **en parejas** y a cada pareja el catedrático les asignará un dataset, de modo que no existan dos soluciones idénticas. Estos datasets no están curados, por lo que deben prestar atención a valores faltantes, outliers y duplicados.

#	Dataset	Enlace
1	BigMart Sales Dataset	https://www.kaggle.com/datasets/yasserh/bigmartsalesdataset
2	Sales Data	https://www.kaggle.com/datasets/jehanzaibbhatti/sales-data

#	Dataset	Enlace
3	Telecommunications Industry Customer Churn Dataset	https://www.kaggle.com/datasets/aadityabansalcodes/telecommunications-industry-customer-churn-dataset
4	FoodMart Dataset	https://www.kaggle.com/datasets/dermisfit/foodmart-dataset

Problema de negocio

Cada pareja debe proponer una pregunta de negocio sobre su dataset. **La pregunta debe ser aprobada antes de iniciar el desarrollo.** La propuesta debe definir:

Elemento	Descripción
Contexto	La empresa o área y por qué el problema es relevante.
Stakeholder	Quién utilizará los resultados y qué decisión necesita tomar.
Pregunta de negocio	Una pregunta concreta que la solución responderá.
Objetivo analítico	La pregunta traducida a una tarea analítica (clasificación, regresión, segmentación, detección de anomalías, etc.).
Métrica de éxito	Cómo se medirá si la solución es útil, técnica y comercialmente.
Estimación de impacto	Qué cambiaría para el negocio si se adopta la solución.

Requisitos del proyecto

Modelo

Deben aplicar al menos uno de los modelos o enfoques vistos en clase, seleccionado de acuerdo con el problema. El proyecto debe:

1. Crear una línea base y justificar la selección del algoritmo.
2. Realizar el preprocesamiento correspondiente (valores faltantes, outliers, feature engineering, etc.).
3. Entrenar y evaluar el modelo con métricas apropiadas para el problema.
4. Ajustar hiperparámetros cuando sea razonable.
5. Interpretar los resultados y discutir limitaciones, sesgos y riesgos.

El modelo final no debe elegirse solo por tener la métrica más alta: también deben considerar utilidad de negocio, interpretabilidad y facilidad de implementación. Pueden hacer uso de MLflow, SHAP o FastAPI.

Kedro

El proyecto debe estar implementado en Kedro y ejecutarse desde la línea de comandos (kedro run) sin pasos manuales no documentados. Como mínimo debe incluir:

- Pipelines de carga, limpieza y transformación, entrenamiento y evaluación.
- Nodos con responsabilidades claras.
- Data catalog (catalog.yml) y parámetros configurables (parameters.yml).
- Outputs reproducibles y un README con instrucciones de instalación y ejecución.

GitHub y GitHub Actions

Cada pareja debe trabajar en un repositorio de GitHub accesible, con el proyecto Kedro, dependencias, pruebas y documentación de las decisiones importantes. El repositorio debe incluir al menos un workflow que se ejecute en cada push y pull request, y que:

1. Instale las dependencias.
2. Ejecute validaciones de calidad de código con Ruff.
3. Ejecute las pruebas automatizadas.
4. Verifique que el pipeline se ejecuta correctamente.

Entrega

Deben entregar antes de la fecha estipulada, por medio de MiU un archivo .zip con:

1. Un reporte .pdf corto con las secciones descritas abajo.
2. El proyecto Kedro completo, con código, pruebas, workflow de GitHub Actions y README.
3. El enlace al repositorio de GitHub.
4. El modelo entrenado y los resultados necesarios para reproducir el proyecto, si corresponde.
5. La diapositiva de la presentación.

Reporte

El reporte debe ser comprensible para una persona que no sea especialista en Data Science e incluir: Introduction, Business problem, Data, Methods, Model selection, Results, Business interpretation, Recommendations, Limitations y Conclusion.

Presentación

Presentarán su proyecto en **la fecha estipulada** mediante **una sola diapositiva** en formato de infografía, similar a los pósteres con los que se presentan los papers académicos. La diapositiva debe reunir toda la información del proyecto de forma visual y concisa: problema y pregunta de negocio, dataset, metodología, modelo seleccionado, resultados y métricas principales, recomendaciones, limitaciones y arquitectura de la solución. Ambos integrantes deben participar en la exposición.

Calificación

Categoría	Qué se evalúa	Puntos
Problema de negocio	- Claridad del contexto y del stakeholder. - Relevancia de la pregunta y objetivo analítico. - Métrica de éxito e impacto.	10
Exploración y preprocesamiento	- Exploración inicial y visualizaciones relevantes. - Tratamiento de faltantes, duplicados y outliers. - Transformaciones justificadas y feature engineering.	15
Selección, entrenamiento y evaluación del modelo	- Línea base y justificación del modelo. - Métricas apropiadas y ajuste de hiperparámetros.	10

Categoría	Qué se evalúa	Puntos
	- Interpretación de resultados y limitaciones.	
Proyecto Kedro y reproducibilidad	- Pipelines y nodos bien separados. - Data catalog y parámetros configurables. - Ejecución reproducible y README claro.	10
GitHub y GitHub Actions	- Repositorio organizado y dependencias configuradas. - Workflow funcional con validaciones, pruebas y ejecución del pipeline.	10
Pruebas y calidad de código	- Uso de Ruff, docstrings y código claro.	5
Reporte	- Organización y claridad. - Justificación metodológica, tablas y visualizaciones. - Interpretación para negocio y conclusiones.	20
Presentación	- Claridad y síntesis visual de la información. - Comprensible para una audiencia no técnica. - Recomendaciones y participación de ambos integrantes.	20
Total		**100**

Integridad académica

No se permite presentar material ajeno como propio. Deben citar correctamente las fuentes externas, código, datasets y documentación utilizados.